

Inteligencia de Negocios

Profesor:

Ing. Ariel Torres (@jarieltorres)

Clase 03

Modelado Físico (Parte I)

Modelado Físico

Debemos pasar el modelo lógico que hicimos (conceptual), al modelo físico (tablas de una BD). Al igual que un DER de un sistema transaccional habrá cambios en este **pasaje lógico a físico**. Para realizar esta tarea existen diferentes **técnicas de modelado** según la realidad del negocios

- Armar un modelo físico es dar un **soporte en tablas** a todos los objetos identificados en el modelo multidimensional
- Lo que se **define** en esta etapa son **las tablas del Data Warehouse (DW)**
- El modelo físico se compone exclusivamente de tablas y columnas

Tablas Look Up



Las tablas de look up o tablas maestras son las que almacenan los elementos de un atributo

- Podemos crear una tabla de look up por cada atributo (lo que se conoce como esquema *snowflake* o copo de nieve) o una tabla por dimensión (lo que se conoce como esquema *star* o estrella)
- Tienen una columna por attribute form + una columna por cada padre (del atributo)

Tablas de Relación



Las *tablas de relación* se utilizan cuando hay una relación *muchos a muchos entre dos atributos*

Tablas de Hechos



Las *tablas de hechos* o fact tables son las que almacenan los valores de los *hechos*

- Son las tablas de mayor cantidad de filas (ocupan más del 90% del data warehouse)
- Tienen una columna por cada hecho + una columna por cada atributo del nivel al cual se conocen los hechos

Tablas de Hechos



Las *tablas base* o base tables son las que guardan los hechos *al mínimo nivel de detalle*.

- Son imprescindibles en términos de información
- Habrá tantas tablas de hechos como conjunto de hechos se conozcan al mismo nivel
- En general tienen una gran cantidad de filas
- Sus filas se llenan a partir de los datos que provienen de los sistemas OLTP

Tablas de Hechos



Las *tablas agregadas* se crean exclusivamente para reducir el tiempo de respuesta de las consultas

- Son prescindibles en términos de información (no dicen nada que no sea dicho por una tabla base ... Pero lo que dicen lo dicen más rápido)
- En general tienen pocas filas
- Su contenido **se calcula a partir de las tablas base**

Ejemplo: Tablas Look Up



Provincia

@ID

@DESC

- 1, Santa Fe
- 2, Buenos Aires
- 3, Chubut

LK_PROVINCIA

Provincia_SK	Provincia_DESC
1	Santa Fe
2	Buenos Aires
3	Chubut
...	...



Una fila por **elemento** del atributo



Una columna por **attribute form**

Ejemplo: Tablas Look Up

 Provincia



LK_CIUADAD

Ciudad_SK	Ciudad_DESC	Provincia_SK
11	Junín	1
12	Pehuajó	1
31	Paso del Sapo	3



Una columna por
attribute form

+

Una columna por cada
padre

Ejemplo: Tablas de Hechos

 Empleado

 Día

 Artículo

 Ventas \$

 Unidades Vendidas

BT_VENTAS_EMP_DIA_ART

Empleado_SK	Dia_SK	Articulo_SK	Ventas_\$	Unid_Vend
111	20130102	17	\$2	4
112	20130102	17	\$4	8
113	20130102	17	\$4	8
...	...	...	...	...

Ejemplo: Tablas Agregadas

BT_VENTAS_EMP_DIA_ART

Empleado_SK	Dia_SK	Articulo_SK	Ventas_\$	Unid_Vend
111	20130102	17	\$2	4
112	20130104	17	\$4	8
113	20130107	17	\$4	8
...	...	...	...	...

AGG_VENTAS_EMP_MES


Empleado_SK	Mes_SK	Ventas_\$	Unid_Vend
111	201301	\$4,200	315
112	201301	\$6,700	405
113	201301	\$8,200	617
...	...	...	...

Ventajas del modelado dimensional

✓ Fácil de extender

- Agregar un nuevo hecho no planeado, siempre y cuando sea compatible con la granularidad ya definida
- Agregar una nueva dimensión teniendo en cuenta que un único valor de la dimensión esté relacionado con los hechos de la tabla
- Agregar en una dimensión un atributo que no había sido planeado
- Romper una dimensión existente llevándola a un nivel de granularidad menor a partir de un momento dado


Star Schema



- Una tabla por dimensión.
- Hay menos tablas involucradas.
- Los queries son más fáciles de construir.
- Los queries son resueltos más rápidos porque se necesita acceder a menos tablas (aunque mas uso del DISTINCT).

Snowflake Schema

Item



- Más difícil de entender para el usuario final.
- Más lento para traer datos.
- Son más fáciles de llenar las tablas.
- Mayor número de tablas.

BT_VENTA
id_fecha
id_tienda
Id_cliente
Id_item
Volumen_vta
Importe_vta

LK_ITEM
Id_item
Des_item
Id_genero


LK_GENERO
Id_genero
Des_genero
Id_categoria

LK_CATEGORIA
Id_categoria
Des_categoria

Snowflake Schema

Completamente normalizado


- ✓ Las tablas lookup contienen el id propio, la descripción y el id del padre.
- ✓ Se minimiza la redundancia de datos y espacio de almacenamiento.
- ✓ Requiere numerosos joins si quiero datos de las tablas de más alto nivel.



Snowflake Schema

Moderadamente Normalizado


- ✓ Las tablas lookup tienen el id propio, su descripción, y todos los id de sus ancestros.
- ✓ Reduce significativamente la cantidad de joins para consultar datos dentro de la jerarquía.
- ✓ Hay algo de redundancia.



Snowflake Schema

Completamente Desnormalizado

- ✓ Las tablas look up tienen el id propio, su descripción, y todos los id y descripciones de sus ancestros.
- ✓ Elimina del todo los joins para buscar las descripciones de los diferentes niveles.
- ✓ Ocupa mucho espacio de almacenamiento.



Tipos de Hechos

- ✓ Aditivos: son hechos que pueden ser sumados a través de todas las dimensiones.
- ✓ Semi aditivos: se pueden sumar en algunas dimensiones y en otras no.
- ✓ No aditivos: no tienen sentidos de ser sumadas.

BT_VENTA
id_fecha
id_tienda
Id_item
Volumen_Vta

El **Volumen_Vta** es un hecho **aditivo**. Tiene sentido sumarlo por cualquiera de los atributos.

Tipos de Hechos

- ✓ Aditivos: son hechos que pueden ser sumados a través de todas las dimensiones.
- ✓ Semi aditivos: se pueden sumar en algunas dimensiones y en otras no.
- ✓ No aditivos: no tienen sentidos de ser sumadas.

BT_BALANCE
id_fecha
id_cuenta
Balance_actual
Margen_ganancia

El **balance_actual** es un hecho **semi aditivo**. Tiene sentido sumarlo por cuenta, pudiendo saber el balance total de un día. Pero carece de sentido sumarlo para todos los días.

El **margen_ganancia** es un hecho **no aditivo**. Es un porcentaje a nivel cuenta y día, no tiene sentido si lo sumo por cuentas o por día.

Tipos de Fact Tables

- **Acumulativas:** describen que fue pasando durante un periodo de tiempo. Por lo general los hechos son en su mayoría aditivos.
- **Snapshot:** describen el estado de algo en un momento determinado. Por lo general los hechos son no aditivos y semi aditivos.

BT_VENTA
id_fecha
id_tienda
Id_item
Volumen_Vta

Acumulativa

BT_BALANCE
id_fecha
id_cuenta
Balance_actual
Margen_ganancia

Snapshot

Surrogate Key

“Es aconsejable no usar como claves los códigos de producción”

Las SK eliminan los siguientes problemas

- En producción se pueden usar códigos que se habían depurado y aún existen en el dw
- En producción puede cambiar la descripción de un producto o cliente, sin cambiar el código que lo representa.
- Producción podría cambiar el formato de sus claves, por ejemplo de ser numéricas a ser alfanuméricas.
- ✓ Las claves de las tablas ocuparán menos espacio.
- ✓ Son más fáciles de mantener.